



**UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE – UFRN**

**PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA  
ELÉTRICA E DE COMPUTAÇÃO – PPGEEC**

**DISCIPLINA: REDES NEURAIS E DEEP LEARNING - PPGEEC2321**

**PROFESSOR: ADRIÃO DUARTE DORIA NETO**

**ALUNO: WILSON FRANCELINO DE MORAIS JÚNIOR**

# **An Open-Source and Reproducible Implementation of LSTM and GRU Networks for Time Series Forecasting**

**Autores: Gissel Velarde, Pedro Brañez, Alejandro Bueno, Rodrigo Heredia,  
Mateo Lopez-Ledezma**

# Introdução

## Objetivo:

- Apresentar uma implementação **open-source e reprodutível** de redes **LSTM** e **GRU** aplicadas à previsão de séries temporais.

## Conjuntos de Dados Utilizados:

- **S&P BSE BANKEX:** Série temporal de preços de fechamento de 10 instituições financeiras.
- **Activities Dataset:** Séries sintéticas que simulam atividades semanais: 5 dias de alta atividade e 2 dias de baixa atividade.

# Introdução

## Metodologia:

- Treinamento de modelos **LSTM** e **GRU** usando uma **única série** temporal (com padrões recorrentes e pré-processadas).

## Métricas de Avaliação:

- **RMSE** – Root Mean Squared Error (Erro Quadrático Médio)
- **DA** – Directional Accuracy (Acurácia Direcional)

# Justificativa do uso de LSTM e GRU

## **LSTM (Long Short-Term Memory):**

- Possui células de memória com portas (entrada, esquecimento e saída).
- Capaz de modelar dependências de longo prazo.


## **GRU (Gated Recurrent Units):**

- Portas de atualização e redefinição.
- Estrutura mais simples, treinamento mais rápido que LSTM.


## **Estudos anteriores mostram:**

- LSTM supera métodos clássicos como ARIMA (Autoregressive Integrated Moving Average).
- GRU e LSTM possuem desempenho similar, mas GRU é mais eficiente computacionalmente.
- Incluem comparações com CNN e ELM.

# Redes Neurais Recorrentes (RNN)



LSTM



GRU

# **Método - Pipeline de Treinamento e Avaliação**

## **Entrada:**

- Séries temporais (valores ao longo do tempo).

## **Pré-processamento:**

- Normalização dos dados (escala padrão entre 0 e 1).

## **Divisão dos Dados:**

- Definição do número de amostras para teste.
- Criação dos conjuntos de treinamento e teste.

# Método - Pipeline de Treinamento e Avaliação

## Treinamento:

- Utilizada apenas a primeira série temporal de cada dataset.
- Preparação da série em formato de janelas temporais (60 dias).
- Treinamento independente de dois modelos: LSTM e GRU

## Avaliação:

- Teste em todas as séries do conjunto de teste (Últimas 251 amostras).
- Métricas utilizadas: RMSE (Root Mean Squared Error) e DA (Directional Accuracy)

## Pós-processamento:

- Desnormalização dos valores previstos.
- Análise visual dos resultados.

# Arquitetura das Redes e Treinamento

## Arquitetura das Redes (LSTM e GRU):

- 1 camada recorrente com 128 unidades:
  - Usa funções de ativação: **Sigmoid** (portões) e **tanh** (estados)
- 1 camada densa: Número de neurônios = número de passos à frente ( $f$ ) (Ex.:  $f = 1$  ou  $f = 20$ )

**Otimizador:** Adam

**Função de perda:** Erro Quadrático Médio (MSE)

**Épocas:** 200 épocas

- Definido empiricamente (balanceando erro e tempo de treino).




# Entities in the S&P BSE-BANKEX Dataset

Number	Entity	Symbol
1	Axis Bank	AXISBANK.BO
2	Bank of Baroda	BANKBARODA.BO
3	Federal Bank	FEDERALBNK.BO
4	HDFC Bank	HDFCBANK.BO
5	ICICI Bank	ICICIBANK.BO
6	Indus Ind Bank	INDUSINDBK.BO
7	Kotak Mahindra	KOTAKBANK.BO
8	PNB	PNB.BO
9	SBI	SBIN.BO
10	Yes Bank	YESBANK.BO


# S&P BSE-BANKEX Dataset

## Sem normalização




# S&P BSE-BANKEX Dataset


## Com normalização



# Activities Dataset – Sem normalização



# Treinamento - Função de perda



# Resultados

Table 2: One-step ahead forecast on Activities dataset.

	RMSE			DA		
	LSTM	GRU	Baseline	LSTM	GRU	Baseline
<b>Mean</b>	0.2949	0.1268	0.3730	0.6360	0.6236	0.4212
<b>SD</b>	0.0941	0.0425	0.0534	0.0455	0.0377	0.0403

Table 3: Twenty-step ahead forecast on Activities dataset.

	RMSE			DA		
	LSTM	GRU	Baseline	LSTM	GRU	Baseline
<b>Mean</b>	0.1267	0.2048	0.4551	0.6419	0.6261	0.4805
<b>SD</b>	0.0435	0.0683	0.0678	0.0331	0.0255	0.0413

# Resultados

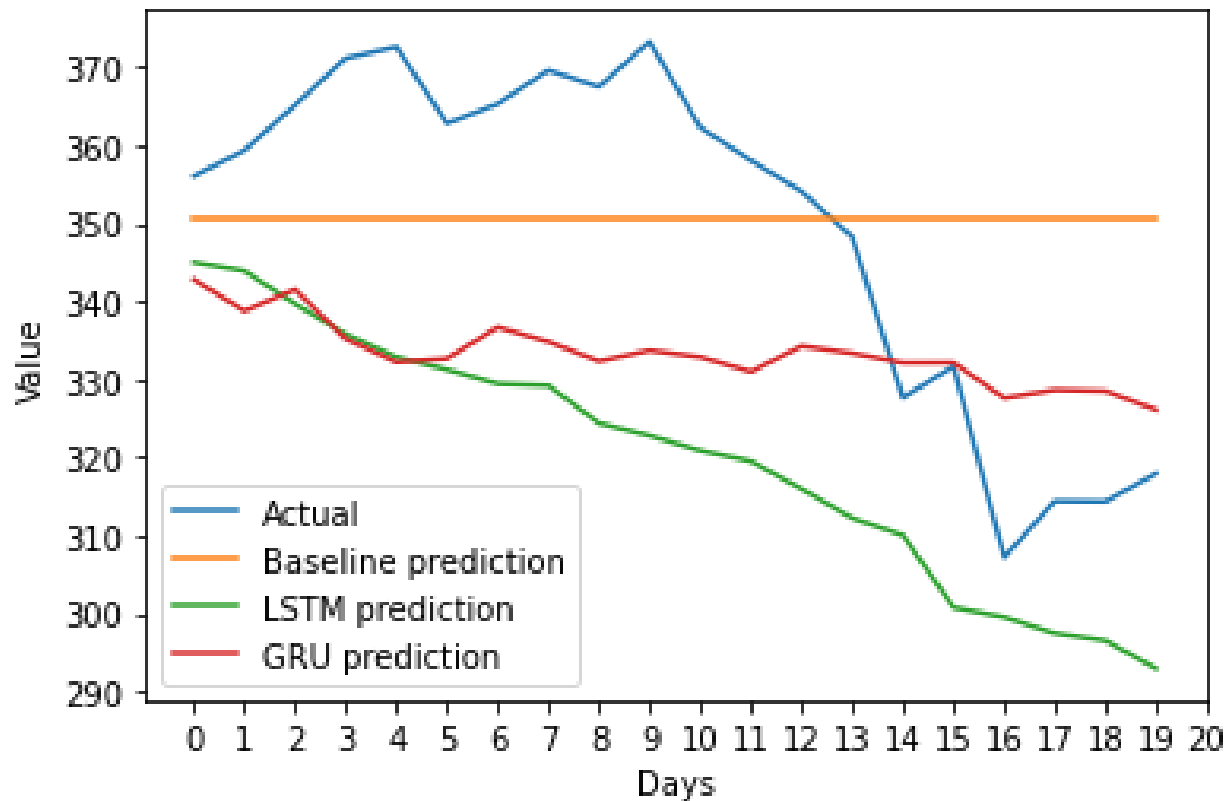
Table 4: One-step ahead forecast on BANKEX dataset.

	RMSE			DA		
	LSTM	GRU	Baseline	LSTM	GRU	Baseline
<b>Mean</b>	0.0163	0.0163	0.0161	0.4884	0.4860	0.4880
<b>SD</b>	0.0052	0.0056	0.0056	0.0398	0.0385	0.0432

Table 5: Twenty-step ahead forecast on BANKEX dataset.

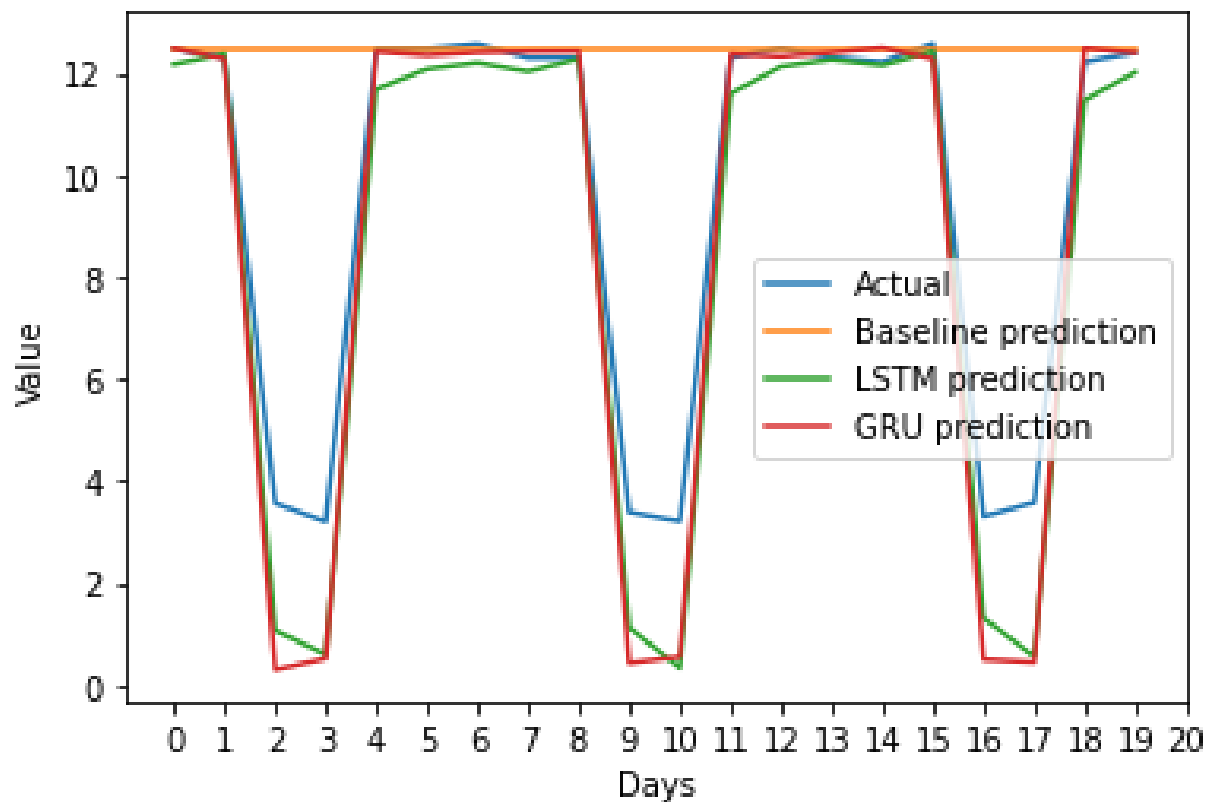
	RMSE			DA		
	LSTM	GRU	Baseline	LSTM	GRU	Baseline
<b>Mean</b>	0.0543	0.0501	0.0427	0.5004	0.5004	0.4969
<b>SD</b>	0.0093	0.0064	0.0113	0.0071	0.0087	0.0076

# Previsão de 20 passos à frente - S&P BSE-BANKEX Dataset






# Previsão de 20 passos à frente - Activities Dataset



**Previsão de 1 passo a frente. Preço de fechamento real e previsto nos primeiros 100 dias do banco Yes set. Preço de fechamento em rúpia indiana (INR).**



# Referências

- Fonte do artigo: [arXiv:2504.18185v1](https://arxiv.org/abs/2504.18185v1)
- Link do artigo: <https://arxiv.org/abs/2504.18185>
- Link do Código e datasets: <https://github.com/Alebuenoaz/LSTM-and-GRU-Time-Series-Forecasting>
- Link do código adaptado: [https://github.com/wilsonfmjr/PPGEEC2321---REDES-NEURAIIS-E-DEEP-LEARNING/blob/main/LISTA\\_2/Questao\\_5.ipynb](https://github.com/wilsonfmjr/PPGEEC2321---REDES-NEURAIIS-E-DEEP-LEARNING/blob/main/LISTA_2/Questao_5.ipynb)